

Optimiser la gestion des données chez BottleNeck



Patty CHANG
formation Data Analyst


Contexte et objectifs

Objectif :


- Optimiser les ventes
- Comprendre le comportement des clients
- Gérer les stocks



Données



Analyse



Action

Datasets disponibles

Des données :

- ERP (Enterprise Resource Planning)
- Extraction du site Web
- Table de liaison

RGPD respecté :

Absence de données directement identifiantes

Caractéristiques des données

ERP :

- 825 observations
- 6 colonnes
- Données :
 - product_id
 - price
 - stock_quantity
 - stock_status
(instock / outofstock)

WEB :

- 1513 observations
- 29 colonnes
- Données :
 - sku
 - total_sales
 - tax_status (taxable)
 - product_type (vin, gin, whisky...)

Liaison :

- 825 observations
- 2 colonnes
- Données :
 - id_web (734 valeurs)
 - product_id

Nettoyage et traitement

- Suppression des doublons
- Gestion des valeurs manquantes
- Correction d'incohérence
- Vérifier les outliers (le z-score et l'intervalle interquartile)

	product_id	onsale_web	price	stock_quantity	stock_status	purchase_price	stock_status_2
4	4039	1	46.0	3	outofstock	23.77	instock
398	4885	1	18.7	0	instock	9.66	outofstock

Points d'attention – valeurs aberrantes

- Valeurs aberrantes

	product_id	price	purchase_price	stock_quantity	marge
151	4233	-20.0	10.33	0	-2.936108
469	5017	-8.0	4.34	0	-2.843318
739	6594	-9.1	4.61	19	-2.973970

	product_id	price	purchase_price	stock_quantity	marge
210	4355	12.65	77.48	97	-0.836732

Points d'attention – valeurs atypiques/manquantes

- Valeurs atypiques

	product_id	onsale_web	price	stock_quantity	stock_status
449	4973	0	10.0	-10	outofstock
573	5700	1	44.5	-1	outofstock


- Données manquantes

	sku	total_sales	tax_status	product_type	post_type
	8	NaN	NaN	NaN	NaN
	20	NaN	NaN	NaN	NaN
	30	NaN	NaN	NaN	NaN
	37	NaN	NaN	NaN	NaN
	41	NaN	NaN	NaN	NaN
	...	...	...	...	...
	1384	NaN	NaN	NaN	NaN
	1429	NaN	NaN	NaN	NaN
	1432	NaN	NaN	NaN	NaN
	1445	NaN	NaN	NaN	NaN
	1457	NaN	NaN	NaN	NaN

85 rows x 5 columns

Fusion des datasets

- Attributs conservés et minimalistes
- Vérifier les clés primaires/étrangères



Vigilance et difficultés

- Données manquantes sur fusion


product_id	onsale_web	price	stock_quantity	purchase_price	stock_status_clean	id_web	sku	total_sales
6902	0	31.0	6	16.50	instock	NaN	NaN	NaN
6903	0	27.0	54	14.23	instock	NaN	NaN	NaN
6900	0	30.0	0	16.28	outofstock	NaN	NaN	NaN
6901	0	20.0	0	10.64	outofstock	NaN	NaN	NaN
6898	0	30.0	51	14.88	instock	NaN	NaN	NaN

- Vérifications effectuées pour éviter la duplication

	product_id	post_type_y
0	4142	attachment
1	4142	product
2	6126	product
3	6126	attachment

Analyse du prix – vérification des outliers

- Boxplot pour visualiser des outliers



- Z-score

Nombre d'outliers : 17
Proportion d'outliers : 2.08 %

- Intervalle interquartile

Nombre d'outliers : 36
Proportion d'outliers : 4.4 %

Analyse du prix – justification des outliers

- Anomalies vs. Produits de premium

	product_id	price	purchase_price	product_type	post_name	price_zscore
207	4352	225.0	137.81	Champagne	champagne-egly-ouriet-grand-cru-millesime-2008	7.228199
457	5001	217.5	116.87	Vin	david-duband-charmes-chambertin-grand-cru-2014	6.946746
630	5892	191.3	116.06	Champagne	coteaux-champenois-egly-ouriet-ambonnay-rouge-...	5.963538
225	4402	176.0	78.25	Cognac	cognac-frapin-vip-xo	5.389375
593	5767	175.0	90.42	Vin	camille-giroud-clos-de-vougeot-2016	5.351848

Analyse du prix – limites de l'analyse univariée

- Analyse isolée sans lien avec ventes ou marges
- Sensibilité aux valeurs extrêmes
- Absence de segmentation par type de produit
- Non prise en compte de la dimension temporelle


Approche pour analyses complémentaires

- Principe de Pareto sur des ventes en CA et en quantité
- Calcul du nombre de mois de stock
- Analyse du taux de marge
- Corrélations entre des stocks, des ventes et des prix


Loi de Pareto (règle des 80/20)

- en CA :
 - 443 articles
 - 62.045 %
- en quantité :
 - 439 articles
 - 61.485 %

Top 10 des articles par chiffre d'affaires




Top 10 articles en quantité



Gestion des stocks – nombre de mois


- Produits avec le plus grand nombre de mois de stock

Top 10 nombre de mois de stock




- Les moyennes par type de produits (la moyenne globale : 5.02 mois)

Nombre de mois de stock par type



Taux de marge – profitabilité par type de produits


Distribution du taux de marge par type de produit



Corrélations : stock – price – sales

- stock vs. sales : 0,45
-> corrélation positive modérée
- stock vs. price : -0,09
-> pas significativement lié
- price vs. sales : -0,52
-> corrélation négative modérée

Heatmap de corrélation entre stock, sales et price



Recommandations

- Suivi des stocks et marges
- Prioriser les produits les plus profitables
- Segmentation des produits et des clients pour optimiser le CA
- Standardisation de la saisie des données
- Analyses supplémentaires (saisonnalité, promotions)

Processus de nettoyage



Audit

Comprendre avant d'agir




Validation

Vérification post-fusion



Nettoyage

- Nettoyage structurel
- Gestion valeurs manquantes
- Traitement outliers
- Feature engineering



Dataset prêt

Traçabilité & reproductibilité

Compétences et apprentissage

- Points forts :
calculs de KPI, gestion des types de données et formats incohérents
- Difficultés rencontrées :
gestion des outliers, corrélations interprétation, jointures complexes pouvant créer des doublons
- Besoin d'entraînement :
visualisation avancée, analyse statistique plus fine, automatisation de pipelines, création de KPIs complexes