



OPENCLASSROOMS

PROFIL SOCIODÉMOGRAPHIQUE DES ÉTUDIANTS DATA OC

ANALYSE DE L'ÉVOLUTION 2022-2025

**PATTY CHANG
FORMATION DATA ANALYST**

PLAN DE LA PRÉSENTATION

01 

Contexte & Objectifs

02 

Méthodologie &
Pipeline DBT

03 

RGPD & Conformité

04 

Analyse : Genre

05 

Analyse : Âge


06 

Analyse : Géographie

07 

Insights &
Recommandations

CONTEXTE & OBJECTIFS

01 

**Analyser l'évolution du profil
sociodémographique des étudiants des
parcours Data sur 4 ans (2022-2025)**

02 

**Objectiver les tendances en termes de
genre, âge et région**


03 

**Comparer le profil OC à la population
française (INSEE)**

04 


**Alimenter les réflexions stratégiques sur
l'accessibilité et l'égalité des chances**

MÉTHODOLOGIE : WORKFLOW



MÉTHODOLOGIE : PIPELINE DBT

Architecture en 3 couches : Staging → Intermediate → Marts



SOURCES DE DONNÉES & QUALITÉ

4647

Inscriptions brutes

4010

Étudiants uniques

13

Régions

4

Années

TRAITEMENTS APPLIQUÉS

- Valeurs manquantes GENDER
 - NULL → Non renseigné
- Harmonisation régions et genres
 - DOM → DROM
 - Centre-Val de Loire → Centre-Val-de-Loire
- Mapping pour tranches d'âge
 - 30 à 34 ans → 30-34 ans
- Agrégation pour "60 ans ou plus"

CONFORMITÉ RGPD

01 Minimisation des données

- Seules les variables utiles à l'analyse ont été conservées.
- Aucune donnée directement identifiante (nom, prénom, email) n'est présente dans les tables finales.

02 Finalité déterminée

- Le pipeline DBT produit des tables agrégées, jamais de données individuelles en sortie.

03 Pseudonymisation


- Les USER_ID sont des identifiants techniques générés. Il n'existe aucun lien direct avec des informations personnelles identifiantes.

04 Données INSEE (publiques)

- Les données INSEE sont des statistiques agrégées de population, aucune contrainte RGPD applicable.

ÉVOLUTION DES INSCRIPTIONS 2022-2025

Évolution de nombre d'étudiants OC



2022

Année de référence

2023

Premier repli
significatif : **-32%**


2024

Point bas : **-50%** vs
2022

2025

Rebond partiel **+12%**


RÉPARTITION PAR GENRE



Analyse

- Pic de féminisation en 2025 : 31% → signe d'une légère progression
- L'évolution de la part "Non renseigné" (42% → 7%) améliore la fiabilité des analyses genre

ÉVOLUTION DE FÉMINISATION




Analyse

- L'écart diminue légèrement pendant 4 ans
- Un déséquilibre hommes/femmes qui reste marqué

RÉPARTITION PAR TRANCHE D'ÂGE

Écart de répartition par tranche d'âge : OC vs INSEE (2022-2025)




Analyse

- 30-34 ans : tranche dominante sur toute la période (27% en 2022, 23% en 2025)
- Rajeunissement net : les 20-24 ans passent de 1% à 9% entre 2022 et 2025
- Les 25-44 ans concentrent ~75% des étudiants : profil de reconversion professionnelle confirmé

RÉPARTITION PAR TRANCHE D'ÂGE

Écart de répartition par région : OC vs INSEE (2022-2025)



Île-de-France

Surreprésenté
46% OC vs 18% INSEE → × 2,5

Territoires isolés

Sous-représenté
Corse, DROM : < 1%

Inégalités

Enjeu : Accès numérique et
couverture réseau

RECOMMANDATIONS STRATÉGIQUES

01 Renforcer l'attractivité féminine

- Développer des communications et partenariats ciblés (associations féminines dans la tech, témoignages d'alumni).
- Objectif : porter la part féminine au-delà de 40%.

02 Adresser les territoires sous-représentés

- Programmes de bourses ou tarifs adaptés pour les étudiants hors des grandes métropoles.
- Partenariats avec les Régions pour le financement.

03 Rajeunir l'audience

- Renforcer les partenariats avec les universités et lycées.
- La tendance 2022 -2025 (20-24 ans : 1% → 9%) confirme la faisabilité.

04 Mettre à jour le pipeline annuellement

- Automatiser l'ingestion des données INSEE dans Snowflake.
- Prévoir un tableau de bord de suivi live connecté aux tables DBT.

REPRODUCTIBILITÉ & LIMITES

Ce que le pipeline garantit

- Reproductibilité : “dbt run” produit les mêmes résultats à chaque exécution
- Intégrité : tests DBT automatiques (unique, not_null, accepted_values)
- Traçabilité : chaque modèle est versionné et documenté en YAML
- Conformité RGPD : pas de données personnelles dans les tables finales

Limites à connaître

- 7 % de genres non renseignés : analyse genre partielle
- Région déclarée à l’inscription : peut ne pas refléter la résidence réelle
- Pas de données sur le taux de réussite ou d'abandon par profil
- Pas de données détaillées sur le 14 % d'étudiants inscrits plusieurs fois

CONCLUSION

Le profil des étudiants Data OC est :

- Actif en reconversion
- Majoritairement masculin
- Concentré en Île-de-France
- Âgé de 30 à 44 ans

Axes d'amélioration :

- Féminisation
- Accessibilité
- Égalité des chances géographiquement
- Rajeunissement
- Enrichir l'offre de formation avec des sujets émergents (IA, LLM, MLOps...)